7-1 · LangChain 챗봇 기초 · 정리·회고 0.5H

정리·회고

부품 일곱 개를 한 장으로, 7-2 문서 처리 준비

수도권ICT 이노베이션스퀘어
데이터 엔지니어링 & RAG 파이프라인 160H · 3기

이 시간의 목표

30분 뒤에는

① LangChain 부품 일곱 개의 역할과 코드 모양을 한 장으로 정리한다

② 오늘의 체크리스트를 스스로 확인한다

③ 자주 겪는 오류 네 가지의 원인과 해결을 안다

④ 7-2 문서 분할에 쓸 패키지 셋을 설치한다

모델이 지어낸 답을 봤다면 오늘은 성공 — 그 문제를 고치는 것이 이번 주의 일입니다

오늘의 요약

부품 일곱 개 — 역할과 코드

부품	역할	코드
ChatModel	LLM 호출	llm.invoke(...)
PromptTemplate	메시지 틀	from_messages([...])
OutputParser	원하는 형태로 꺼내기	StrOutputParser()
체인	부품 잇기	prompt | llm | parser
SystemMessage	역할·규칙 지정	체인의 첫 메시지
이력	멀티턴 기억	메시지 목록을 매번 다시 보냄
temperature	답의 무작위성	사실 조회는 0 쪽

llm 은 rag_env.py 가 만든다 — .env 의 LLM_PROVIDER 로 경로를 바꿔도 실습 파일은 그대로(심화 과제 ④)

오늘의 체크리스트

열두 개를 여덟 줄로 — 스스로 확인해 보세요

1. LLM 이 학습 시점까지만 알고 모르는 것을 지어낼 수 있다는 것을 확인했다
2. RAG 가 그 한계를 어떻게 푸는지 한 문장으로 말할 수 있다
3. rag_env.py 하나로 고른 경로의 첫 호출에 성공했다
4. 응답 메타데이터에서 토큰 사용량을 봤다
5. ChatPromptTemplate 의 {빈칸}에 값을 채워 체인을 실행했다
6. 파서 유무에 따라 결과 타입이 달라지는 것을 확인했다
7. 시스템 메시지·temperature 를 바꿔 답이 달라지는 것을 봤다
8. 이력을 안 보내면 잊고, 누적하면 기억하고, 턴이 늘면 토큰이 커진다

자주 겪는 오류

증상으로 찾는 원인과 해결

증상	원인	해결
401 / AuthenticationError	.env 의 키가 비었거나 오타	cat .env 로 확인 .env 는 week7 폴더에
Connection refused (포트 11434)	Ollama 컨테이너 (또는 앱)가 안 떠 있다	docker start ollama → curl localhost:11434
model not found 404	모델명 오타 · 그 키로 못 쓰는 모델	공식 문서 이름과 대조 Ollama 는 ollama list 이름
429 Rate limit 반복	짧은 시간 과다 호출 · 무료 한도 초과	호출 사이 간격 두기 반복 실험 횟수 줄이기

rag_env.py 가 PROVIDER = ollama 를 찍으면 .env 를 못 읽은 것 · 429 는 2-5 의 크롤링 예절과 같은 이야기

예상 질문

자주 나오는 질문 네 가지

1. **파인튜닝과 RAG 중 뭘 써야 하나요?**
   문서가 자주 바뀌거나 출처를 밝혀야 하면 RAG — 말투·형식을 바꾸는 것이 목적이면 파인튜닝

2. **로컬 모델로도 충분한가요?**
   구조를 배우는 데는 충분 — 답의 품질은 상용 모델이 낫지만 파이프라인은 완전히 같다

3. **이력을 DB 에 저장하면 되나요?**
   된다 — 다만 저장한다고 토큰이 줄지는 않는다, 보낼 때는 여전히 전체가 간다

4. **답이 매번 달라서 테스트가 어렵습니다**
   temperature 0 — 그래도 완전히 같진 않으니 「필요한 내용이 들어 있는가」로 테스트

다음 차시 준비

7-2 를 위한 준비 — 패키지 셋만

1. **가상환경 켜기**
   cd ~/data-eng/week7 → source .venv/bin/activate

2. **pip install langchain-community langchain-text-splitters pypdf**
   community 0.4.2 · text-splitters 1.1.3 · pypdf 6.21.4(실측)

3. **ls *.py**
   오늘 만든 실습 파일과 rag_env.py 가 보이면 된다

실습 문서

7-2 실습

1단계에서

다음 회차 예고

7-2 · 텍스트 데이터 Chunking

01

이론 1H

RAG 파이프라인과
Chunking 개념

02

실습 1.5H

Document Loader
와 텍스트 분할

03

실습 1H

Chunk 파라미터
튜닝·품질 비교

04

정리 0.5H

정리·회고

준비: 7-1 가상환경 그대로 · 패키지 셋 · 실습 문서 두 개는 7-2 실습 중에 만든다 — 7-5 까지 검색 대상

7-1 · 정리·회고 0.5H 마무리

다음 회차는 7-2 텍스트 데이터 Chunking

RAG 는 오픈북 시험 — 책을 「찾기 좋은 크기」로 미리 잘라 두는 Chunking 을 배웁니다

- ✓ RAG 파이프라인 전체에서 Chunking 의 위치
- ✓ TextLoader·PyPDFLoader 로 한글 문서 로드
- ✓ chunk_size·chunk_overlap 조절
- ✓ 조합별 분할 결과를 비교해 기준값 정하기

준비할 것

week7 가상환경 · 패키지 셋