7-2 · 텍스트 데이터 Chunking · 수업 전 10분

실습점검 · 환경재설정

7-1 가상환경 · 문서 처리 패키지 셋

수도권ICT 이노베이션스퀘어
데이터 엔지니어링 & RAG 파이프라인 160H · 3기

왜 점검하나

수업 전에 걸러 둘 것

① 7-1 가상환경이 켜지고 rag_env.py 가 모델을 알려 주는지

② 7-1 정리·회고에서 설치한 패키지 셋이 있는지

③ 오늘은 LLM 을 부르지 않는다 — 문서를 읽고 자르기만

1~2단계는 확인 · 문서는 분할 실습 1단계에서 처음 만든다 · 재설정(4단계)은 처음부터 할 때만

흐름

네 단계 — 위에서부터 한 번씩

Docker 도 모델 호출도 없습니다 — 확인 두 가지면 준비 끝

1. 가상환경	2. 패키지	3. 오늘 만들 것	4. 환경 재설정
activate rag_env.py	pip list 세 줄	순서만 확인 아직 치지 않음	파이썬 파일만 처음부터 할 때만

1단계

가상환경을 켜고 rag_env.py 를 실행해 보세요

1 **cd ~/data-eng/week7 → source .venv/bin/activate**
프롬프트 앞에 (.venv) — Windows(WSL2)·macOS·리눅스 모두 같다

2 **python rag_env.py**
PROVIDER = ollama · 모델 = llama3.2 (OpenAI 면 openai · gpt-4o-mini)

3 **No such file or directory: rag_env.py 면**
7-1 실습 1단계의 rag_env.py 를 다시 만든다

오늘은

LLM 호출 없음

2단계

오늘 쓸 패키지 셋을 확인하세요

1. **pip list | grep -i -E "langchain-community|text-splitters|pypdf"**
   세 줄이 나오면 된다

2. **실측 판**
   langchain-community 0.4.2 · langchain-text-splitters 1.1.3 · pypdf 6.21.4

3. **비어 있으면**
   pip install langchain-community langchain-text-splitters pypdf

설치는

7-1 정리·회고

3단계 · 순서만

오늘 만드는 것 — 아직 치지 않는다

무엇	어디서 처음 만드나	남는가
notes.txt **(642자 · 네 장)**	분할 실습 1단계	예 — 7-3 · 7-4 · 7-5 검색 대상
파이썬 파일 6개 **load.py … compare.py**	분할 실습 2~7단계	예
long_notes.txt **(1,247자 · 여덟 절)**	튜닝 실습 1단계	예 — 7-3 · 7-4 · 7-5 검색 대상
파이썬 파일 4개 + doc.md **params.py … md_split.py**	튜닝 실습 2~5단계	예

단계마다 cat > 파일.py << 'EOF' … EOF → python 파일.py — 문서와 파일은 실습 각 단계에서 처음 만든다

4단계

환경 재설정 — 파이썬 파일만 지운다

1. **cd ~/data-eng/week7**
   오늘 실습을 처음부터 다시 하고 싶을 때만

2. **rm -f load.py enc.py split.py ... md_split.py doc.md**
   오늘 만든 파이썬 파일 10개와 doc.md 를 지운다

3. **ls *.txt**
   notes.txt · long_notes.txt 는 남긴다 — 7-3 부터 검색 대상

4. **두 문서를 지웠다면**
   실습 1단계(두 문서를 만드는 상자)를 다시 친다

남기는 것

두 문서

(.txt)

7-2 · 수업 전 10분 마무리

다음은 RAG 파이프라인과 Chunking 개념 (1H)

RAG 여섯 단계를 잡고, 조각 크기가 왜 답의 품질을 좌우하는지 봅니다

- ✓ **RAG 여섯 단계**
- ✓ **왜 잘라야 하는가**
- ✓ **조각 크기의 맞바꿈**
- ✓ **Document 와 메타데이터**

> 막혔다면
> **그 단계 아래 「막혔어요」 · 「질문」**