7-2 · 텍스트 데이터 Chunking · 실습 1H

Chunk 파라미터 튜닝과 품질 비교

재 보고 정한다 — 우리 문서의 기준값

수도권ICT 이노베이션스퀘어
데이터 엔지니어링 & RAG 파이프라인 160H · 3기

이 시간의 목표

1시간 뒤에는

① 여덟 절짜리 long_notes.txt 로 다섯 조합을 잰다

② 문장 중간에서 끝난 조각을 세어 overlap 의 한계를 본다

③ 「CDC」가 든 조각이 크기에 따라 어떻게 다른지 본다

④ 제목 우선 분할을 써 보고 기준값을 근거와 함께 적는다

실측 문서라면 300 · 30 — 7-3 에서 이 값으로 임베딩합니다

실습 흐름

여섯 단계 — 짧은 문서로는 차이가 안 보인다

절마다 내용이 다른 문서를 만듭니다 — 실제 강의 자료나 사내 문서로 해 봐도 좋습니다

1. 긴 문서	2. 조합 비교	3. 절단 검사	4·5. 키워드·MD	6. 기록
long_notes.txt 여덟 절	params.py 다섯 조합	broken.py 마침표로 끝나나	kw_hits.py md_split.py	기준값 표 선택 · 근거

1단계

여덟 절짜리 long_notes.txt 를 만드세요

1. **cat > long_notes.txt << 'EOF' ... EOF**
   수집 · 저장 · 처리 · 분석 · 서빙 · 운영 · 품질 · 보안

2. **절마다 한 문단(150~180자)**
   절마다 내용이 달라야 「어느 조각이 걸리는가」를 볼 수 있다

3. **wc -m long_notes.txt**
   1247 long_notes.txt(실측)

글자 수

1,247자

2단계

params.py — 반복문 하나로 다섯 조합

```
cat > params.py << 'EOF'
# … TextLoader("long_notes.txt", encoding="utf-8").load()
for size, overlap in [(100, 0), (100, 20), (300, 30), (500, 50), (1000, 100)]:
    s = RecursiveCharacterTextSplitter(chunk_size=size, chunk_overlap=overlap)
    cs = s.split_documents(docs)
    lengths = [len(c.page_content) for c in cs]
    # … 조각 수 · 평균 · 최대 길이를 한 줄로 찍는다
EOF
python params.py
```

> **출력 한 줄: size=… overlap=… → 조각 N개, 평균 M자, 최대 K자 — 전문은 사이트 본문에서 복사**

2단계 · 실측

size 가 커질수록 조각은 줄고 길이는 는다

size	overlap	조각 수	평균 길이
100	0	16개	76자
100	20	17개	81자
300	30	6개	206자
500	50	3개	414자
1000	100	2개	622자 (최대 960자)

overlap 을 주면 겹치는 만큼 조각이 하나 더 생길 수 있다 — 100 에서 16 → 17

이 표를 6단계 기록에 옮겨 두세요 — 오늘 산출물의 근거

3단계

broken.py — 문장 중간에서 끝난 조각

size · overlap	중간에서 끝난 조각	까닭
100 · 0	7 / 16	절이 100자에 안 들어감
100 · 20	8 / 17	overlap 으로도 그대로
300 · 30	0 / 6	절 경계에서 잘림
500 · 50	0 / 3	절 경계에서 잘림

검사기는 「마침표로 끝나는가」만 본다 — 몇 개 샘플은 직접 읽어 보는 육안 확인과 함께

예: 「… 외부 API를 부를 때는 호출」 — overlap 은 잘린 문장을 다음 조각에 이어 줄 뿐, 절단 자체를 없애지 못한다

4단계 — 검색 대신 문자열 포함(in)으로

「CDC」가 든 조각 — 크기마다 내용이 다르다

chunk_size=100 — 100자

작으면 근거가 잘린다

- 1개 조각에서 발견
- 「CDC는 … 변경분만 골라 옮깁니다.」
- 「외부 API를 부를 때는 호출」에서 끊김

VS

chunk_size=1000 — 960자

크면 상관없는 글이 딸려 온다

- 1개 조각에서 발견
- 수집 · 저장 · 처리 · 분석 · 서빙 절까지
- 답에 필요한 만큼이 조각 크기의 근거

5단계

md_split.py — Markdown 은 제목 경계를 우선

기본 분할기 — 3개

제목이 앞 조각 끝에 붙고 본문과 떨어진다

- # 데이터 엔지니어링 ## 1. 수집
- 크롤러와 CDC로 … 지킵니다. ## 2. 저장
- … 올립니다. ## 3. 처리 Spark로 …

VS

제목 우선 — 4개

separators 맨 앞에 "\n## " — 제목과 본문이 함께

- # 데이터 엔지니어링
- ## 1. 수집 크롤러와 CDC로 …
- ## 2. 저장 오브젝트 스토리지 …
- ## 3. 처리 Spark로 분산 처리합니다.

6단계

기준값을 정해 기록한다 — 오늘의 산출물

size	overlap	조각 수	평균 길이	중간 절단
100	0			
100	20			
300	30			
500	50			

선택: chunk_size = ___ , chunk_overlap = ___ · 근거 두 줄 · separators 를 조정했다면 함께

실측 문서(long_notes.txt)라면 300 · 30 — 중간 절단 0 · 조각 6개, 7-3 에서 이 값으로 임베딩

확인 포인트

이 1시간이 끝날 때 확인할 것

1. wc -m 이 1247 long_notes.txt 를 보인다
2. size 가 커질수록 조각 수가 줄고 평균 길이가 늘었다
3. 100 에서는 중간 절단 7 · 8개, 300 · 500 에서는 0
4. 100 조각은 근거가 잘리고, 1000 조각은 다섯 절이 딸려 왔다
5. 제목 우선 분할에서 조각마다 제목과 본문이 함께 시작한다
6. 기준값 표에 size · overlap 선택과 근거를 적었다

7-2 · 실습 1H 마무리

다음은 정리·회고 (0.5H)

분할 문법을 한 표로 정리하고, 7-3 을 위한 qdrant-client 와 Qdrant 이미지를 미리 받아 둡니다

- ✓ 하려는 일 ↔ 코드 요약표
- ✓ 오늘의 체크리스트
- ✓ 자주 겪는 오류 네 가지
- ✓ 7-3 준비: qdrant-client · 이미지

가져갈 것

기준값 표(size·overlap·근거)