7-3 · Embedding과 Vector DB · 실습 1.5H

Qdrant 컬렉션 생성·적재·검색 실습

띄우고, 만들고, 넣고, 찾고, 걸러 본다

수도권ICT 이노베이션스퀘어
데이터 엔지니어링 & RAG 파이프라인 160H · 3기

이 시간의 목표

1.5시간 뒤에는

① Qdrant v1.20.0 을 볼륨과 함께 띄우고 대시보드를 연다

② size·distance 를 지정해 컬렉션을 만들고, 차원을 일부러 틀려 본다

③ payload 를 담아 적재하고 query_points 로 의미 검색한다

④ payload 필터를 걸고, 7-2의 조각 전체를 적재·검색한다

8단계의 검색 결과가 7-5에서 LLM 에게 넘길 「근거」가 됩니다

실습 흐름

여덟 단계 — 컨테이너 하나, 컬렉션 둘

단계마다 cat > qd_*.py << 'EOF' … EOF → python — 임베딩은 rag_env.py 의 get_emb()

1. 기동	2. 컬렉션	3. 실패	4·5·6. 적재·검색	7·8. 조각
docker run curl 확인	size=DIM COSINE	size=10 일부러 틀리기	upsert query_points·필터	7-2 조각 적재 근거 확인

1단계

Qdrant 를 볼륨과 함께 띄웁니다

```
docker run -d --name qdrant \
  -p 6333:6333 -p 6334:6334 \
  -v qdrant_storage:/qdrant/storage \
  qdrant/qdrant:v1.20.0

sleep 3   # 서버가 뜰 때까지 잠깐
docker ps --filter name=qdrant
curl http://localhost:6333/collections
```

> 브라우저에서 http://localhost:6333/dashboard 로 웹 대시보드도 열어 두세요

1단계 · 확인 포인트

Up 과 status ok — sleep 을 빼면

1. **docker ps**
   qdrant/qdrant:v1.20.0 · Up · 0.0.0.0:6333-6334 (실측)

2. **curl .../collections**
   {"result":{"collections":[]},"status":"ok",...} 면 정상

3. **sleep 없이 바로 curl 을 치면**
   curl: (56) Recv failure: Connection reset by peer — 몇 초 뒤 다시

까닭

서버가 뜨는 중

2단계

qd_collection.py — 차원에 맞춰 컬렉션

```python
emb = get_emb()
client = QdrantClient(url="http://localhost:6333")
COLLECTION = "lecture_notes"
DIM = len(emb.embed_query("차원 확인"))   # 모델 차원과 반드시 일치

if not client.collection_exists(COLLECTION):
    client.create_collection(
        collection_name=COLLECTION,
        vectors_config=VectorParams(size=DIM, distance=Distance.COSINE),
    )
print(client.get_collection(COLLECTION).config.params.vectors)
```

실측 size=768 distance=<Distance.COSINE: 'Cosine'> (OpenAI 는 1536) · 다시 실행해도 같은 줄

3단계 — 일부러 실패시키기

qd_wrongdim.py — 차원을 틀린 컬렉션에

실측 400 · Vector dimension error: expected dim: 10, got 768 — 모델을 바꾸면 만나는 오류

wrong_dim 준비	v1 을 upsert	except 로 잡기	삭제
있으면 delete size=10 으로 create	768(1536)차원 벡터를 넣기	UnexpectedResponse str(e)[:300]	delete_collection ("wrong_dim")

4단계

qd_upsert.py — payload 를 담아 여섯 문장

id	text	category
0	ETL은 추출, 변환, 적재 순서로…	개념
1	ELT는 먼저 적재한 뒤 안에서 변환	개념
2	Airflow는 워크플로 오케스트레이션…	도구
3	Kafka는 이벤트 스트리밍 플랫폼	도구
4	Iceberg는 오브젝트 스토리지 위의…	저장
5	Spark는 대용량 데이터를 분산 처리	처리

payload = {text, category, source: "lecture"} — 대시보드에서 포인트를 눌러 payload 가 함께 들어갔는지 본다

embed_documents(texts) → PointStruct(id, vector, payload) → upsert · 실측 count=6 · 다시 실행해도 6(같은 id 는 덮어씀)

5단계

qd_search.py — 맞힌 질문과 틀린 질문

질문	실측 1등	판정
작업 순서를 관리하는 도구는?	Airflow 0.525	맞음 — Airflow 도 오케스트레이션도 없는데
실시간으로 데이터가 흘러가게 하려면?	Spark 0.428 (Kafka 3등 0.296)	틀림 — 실시간과 스트리밍을 못 묶음
데이터를 먼저 넣고 나중에 손보는 방식	ETL 0.577 (ELT 2등 0.513)	아쉬움 — ELT 가 맞는데 2등

query_points(query=emb.embed_query(q), limit=3).points · 실측 embeddinggemma — 임베딩이 언제나 맞지는 않는다

6단계

qd_filter.py — 같은 질문, 범위만 좁힌다

필터 없음

「데이터를 옮기는 방법」 limit=3

- ETL 0.516
- Spark 0.467
- ELT 0.367

VS

category = "도구" 만

Filter(must=[FieldCondition(...)])

- Airflow 0.260
- Kafka 0.245
- 도구가 둘뿐 — limit=3 이어도 둘

7단계

qd_chunks.py — 7-2에서 만든 조각을 통째로

TextLoader	Splitter	my_notes	embed → upsert	count
long_notes.txt	chunk_size=300 overlap=30	size=DIM 없을 때만 생성	payload={text, **metadata}	조각 수와 같으면 성공

7-2 에서 정한 300 · 30 을 그대로 쓴다 — 하루하루가 이어진다

실측 조각: 6 · count=6 — 맨 위 DeprecationWarning 두 줄은 7-2 와 같은 안내라 무시

8단계

qd_chunk_search.py — 걸린 조각과 출처

순위	조각	점수	출처
1	[처리] 절	0.534	long_notes.txt
2	[분석] 절	0.266	long_notes.txt
3	[운영] 절	0.232	long_notes.txt

「배치와 스트리밍은 어떻게 다른가요?」 · 1등만 질문과 관련 — 이 조각과 출처가 7-5 에서 LLM 에게 넘길 「근거」

확인 포인트

이 1.5시간이 끝날 때 확인할 것

1. curl .../collections 가 status ok 를 돌려주고 대시보드가 열린다
2. lecture_notes 가 size=768(1536) · Cosine 으로 출력됐다
3. wrong_dim 에서 expected dim: 10, got 768 을 봤다
4. count=6 · 대시보드에서 text·category·source 가 보인다
5. Airflow 없는 질문에 Airflow(0.525)가 1등이다
6. 필터를 걸면 Airflow · Kafka 두 개만 나온다
7. my_notes 가 조각: 6 · count=6 이고 출처가 찍힌다

7-3 · 실습 1.5H 마무리

다음은 정리·회고 (0.5H)

오늘 쓴 명령을 표로 정리하고, 자주 겪는 오류 네 가지를 증상으로 찾아 보고, 7-4 MinIO 연동을 준비합니다

- ✓ 임베딩·Qdrant 명령 요약표
- ✓ 오늘의 체크리스트 14개
- ✓ 오류: dimension·refused·409·엉뚱한 결과
- ✓ 7-4 준비: qdrant Up · pip install minio

가져갈 것

떠 있는 qdrant 컨테이너 그대로