7-5 · Hybrid Search 구현 · 실습 1H

BM25 · 벡터 검색 각각 구현 실습

두 검색기를 따로 만들어 같은 질문을 던져 본다

수도권ICT 이노베이션스퀘어
데이터 엔지니어링 & RAG 파이프라인 160H · 3기

이 시간의 목표

1시간 뒤에는

① lecture_kb 10개를 내려받아 BM25 색인을 만든다

② 「Airflow」「Airflow는」「도구는」 점수로 조사 문제를 본다

③ bm25_rank · vector_rank 를 같은 모양(str id 목록)으로

④ 질문 유형별 강약과 「없는 코드」를 두 검색기로 잰다

여기서 만든 retrievers.py 를 다음 1.5H 의 hybrid.py 가 그대로 불러 씁니다

실습 흐름

여섯 단계 — 파일로 만들고 실행

cat > 파일.py << 'EOF' … EOF → python 파일.py · 사전 준비: 실습점검 1 · 2단계

1. 내려받기	2. 점수 보기	3. 조사 재현	4. 함수 정리	5·6. 강약 · 코드
kb_corpus.py scroll → BM25	bm25_scores.py 「Airflow」	bm25_josa.py 질의 일곱 개	retrievers.py str id 목록	show.py bm25_code.py

1단계

kb_corpus.py — 내려받아 색인까지

내려받기	client.scroll(collection_name=COLLECTION, limit=1000, with_payload=True)
본문 · id	corpus = [r.payload["text"] …] · ids = [str(r.id) …]
색인	BM25Okapi([doc.split() for doc in corpus]) # 공백으로 자른 낱말
부품	text_by_id · short(doc_id) — 결과를 한 줄로 볼 때
실측	색인된 문서 수: 10 · id 예: 06db5e83-…

id 를 str 로 통일 — Qdrant 는 UUID 객체로 돌려주기도 해서, 안 맞추면 같은 문서가 다른 키로 집계된다

2단계

「Airflow」 한 낱말의 점수를 보세요

1. **bm25.get_scores("Airflow".split()) → 상위 5개**
   2.11 [운영] 운영은 파이프라인이 … 한 줄만, 나머지 넷은 0.00(실측)

2. **가장 자세한 「2장 오케스트레이션」은?**
   5위 안에도 없다 — 그 문서는 「Airflow는」으로 조사가 붙어 있다

3. **운영 절은 「Airflow 같은」**
   떨어져 있어서 걸렸다 — 낱말이 글자 그대로 같은가만 본다

찾을 숫자

2.11 과

0.00

3단계

조사가 붙으면 다른 낱말 — 일곱 질의

질의	최고점	왜
Airflow	2.11	운영 절 「Airflow 같은」
Airflow는	1.66	2장 — 걸리는 조각이 다르다
도구	1.66	「이런 도구 위에서」
도구는	0.00	어디에도 없다
파티션	0.00	「파티션으로」「파티션에」뿐
Kafka 파티션	0.00	같은 이유
작업 순서를 관리하는 도구는?	3.50	4단계에서 쓰는 질문

이론 시간의 한계를 직접 본 것 — 실무에서 형태소 분석기를 쓰는 이유

4단계

retrievers.py — 같은 모양의 함수 둘

bm25_rank(query, top_k=5)

점수 0 은 못 찾은 것 — 빼고 걸린 것만

- scores = bm25.get_scores(query.split())
- [ids[i] for i in order[:top_k] if scores[i] > 0]
- 실측: id 둘

VS

vector_rank(query, top_k=5)

emb = get_emb() — 7-4 와 같은 임베딩 모델

- client.query_points(..., query=emb.embed_query(query))
- [str(h.id) for h in hits]
- 실측: 언제나 limit 만큼 다섯

5단계

show.py — 질문 넷, 고른 조각 상위 2

질문	BM25	벡터
「Airflow」	운영 절 하나뿐	2장 · 운영 절
「일정을 정해 두고 도는 작업」	2장 · 운영 절	같음
「Kafka 파티션」	없음 (조사)	3장 스트리밍 1등
「ERR-4021」	장애 대응 수칙 1등	장애 대응 수칙 1등

풀어 쓴 질문 · 조사 붙는 낱말은 벡터가, 글자 그대로의 코드는 둘 다 맞혔다 — 결과를 적어 두세요

6단계

벡터만으로는 놓치는 것 — 없는 코드

1. **guide.txt 에는 ERR-4021 · 5003 · 5017**
   7-4 에서 올린 장애 대응 수칙 — ERR-4012 는 없다

2. **ERR-4021 → BM25 2.02 · 벡터 1등 0.411**
   둘 다 장애 대응 수칙을 찾는다(실측)

3. **ERR-4012 → BM25 0.00 · 벡터 1등 0.355**
   벡터는 비슷한 모양의 수칙을 꽤 높게 — 「없다」를 못 알린다

4. **BM25 는 정확히 0점 — 「없음」을 안다**
   오류 코드 · 품번을 다루면 키워드 검색을 반드시 함께

없는 코드

벡터 1등

0.355

확인 포인트

이 1시간이 끝날 때 확인할 것

1. 색인된 문서 수: 10 — 7-4 의 lecture_kb 와 같다
2. 「Airflow」는 2.11 한 줄, 나머지 넷은 0.00
3. 「도구」 1.66 · 「도구는」 0.00 — 조사가 붙으면 다른 낱말
4. BM25 는 id 둘, Vector 는 다섯 — 맨 앞 둘은 순서만 바뀜
5. 질문 네 개의 강약 표를 적어 두었다
6. ERR-4012 — BM25 0.00, 벡터는 0.355 로 엉뚱한 수칙

7-5 · 실습 1H 마무리

다음은 Hybrid 결합과 산출물 완성 (1.5H)

RRF 로 두 순위를 합치고 답변 체인을 붙인 뒤, 주차 산출물 두 가지를 제출합니다

- ✓ **hybrid.py — rrf() 를 손 계산 예로 assert**
- ✓ **세 방식 비교 · k 실험**
- ✓ **rag.py — 찾은 조각만 근거로 답하기**
- ✓ **vector-schema.yaml · build_kb.py 제출**

가져갈 것

retrievers.py · 강약 표