8-4 · Streamlit 기반의 챗봇 인터페이스 개발 · 실습 1H

Qdrant 검색·LLM 연동

에코 자리에 검색 · 기준값 · LLM 답을

수도권ICT 이노베이션스퀘어
데이터 엔지니어링 & RAG 파이프라인 160H · 3기

이 시간의 목표

1시간 뒤에는

① lecture_kb 가 11 조각인지 먼저 확인한다

② 화면 없이 search_test.py 로 검색만 따로 시험한다

③ 안 · 밖 질문의 1등 점수를 재서 기준값 0.4 를 정한다

④ app.py — 근거가 약하면 LLM 을 부르지 않는 챗봇을 완성한다

화면과 검색을 한꺼번에 만들면 어느 쪽이 틀렸는지 못 찾습니다 — 검색부터

실습 흐름

여섯 단계 — 확인 → 검색 → 기준 → 화면

8-3 에서 DAG 가 넣은 lecture_kb 11 조각을 그대로 씁니다

1. 지식베이스	2. 검색만 시험	3. 기준값	4. RAG 챗봇	5·6. 다듬기
curl count 11	search_test.py	threshold.py 0.4	app.py	근거 개수 · 일부러 실패

1·2단계

검색부터 확인 — 화면을 붙이기 전에

1 **curl -s -X POST .../collections/lecture_kb/points/count**
count 11 — 0 이면 8-3 의 rag_pipeline 을 먼저 돌린다

2 **search_test.py — get_emb() · QdrantClient**
QDRANT_URL 이 없으니 기본값 http://localhost:6333

3 **query_points("lecture_kb", ..., limit=3)**
질문: 「새로 만든 DAG 파일이 목록에 안 보여요」

4 **python search_test.py**
1등 0.536 · incoming/airflow_ops.txt · 2등 notes.txt 0.311 (실측)

확인 안 하면

「다 모른다」로

한참 헤맴

3단계

threshold.py — 1등 점수를 나란히 잰다

구분	질문	1등 점수
안	작업 순서를 관리하는 도구	0.531
안	ERR-4021 대응	0.461
안	Kafka 파티션	0.426
안	새 DAG 파일이 안 보여요	0.536
밖	김치찌개 · 날씨	0.216 · 0.205
밖	영화 · 비트코인	0.155 · 0.234
밖	ERR-4012 (없는 코드)	0.363

실측(Ollama · embeddinggemma) — 7-5 에서 그럴듯한 수칙을 내던 없는 코드 ERR-4012 가 0.363

3단계

기준값 0.4 — 이렇게 정했다

1. **안 질문 0.426 ~ 0.536 은 모두 통과**
   8-3 에서 넣은 문서가 1등으로 걸린다

2. **밖 질문 0.155 ~ 0.234 와 ERR-4012 0.363 은 걸러진다**
   검색 1등이 낮으면 아예 LLM 을 부르지 않는다

3. **0.426 과 0.363 의 틈이 좁다**
   문서가 늘면 다시 잰다

4. **OpenAI 경로는 점수대가 다르다**
   같은 파일을 돌려 내 값을 정하고 결과를 채팅에 남긴다

THRESHOLD

0.4

4단계

app.py — 질문에서 답까지

질문	1) 임베딩	2) 검색	기준값	3) 답
st.chat_input	emb.embed_query	query_points limit = 슬라이더	top < 0.4 면 LLM 안 부름	llm.stream → st.write_stream

get_clients() 에 @st.cache_resource — get_emb · get_llm · QdrantClient 를 한 번만 · 근거는 expander 「검색 근거 보기」

프롬프트: 「아래 컨텍스트만 근거로 한국어로 짧게 답해줘. 없으면 모른다고 답해줘.」

4단계

핵심 줄 — 어디에 무엇을 쓰나

하려는 일	코드
모델 경로	from rag_env import PROVIDER, get_emb, get_llm
기준값	THRESHOLD = float(os.getenv("THRESHOLD", "0.4"))
연결 캐시	@st.cache_resource def get_clients():
검색	qdrant.query_points(COLLECTION, ...).points
건너뛰기	if top < THRESHOLD: 찾지 못했습니다 ...
답 흘리기	answer = st.write_stream(llm.stream(prompt))
근거 표시	with st.expander("검색 근거 보기"):

cat > app.py 로 전체본을 쓰고 streamlit run app.py — 끝낼 때는 그 터미널에서 Ctrl+C

4단계 · 결과

두 질문 — 답하는 것과 막히는 것

작업 순서를 관리하는 도구가 뭐야?

지식베이스를 근거로 「오케스트레이터입니다」

- 근거 1등 0.531 · notes/notes.txt
- 첫 답 약 2분 (실측 123초) — 모델 올리기
- 다음부터는 짧아진다

VS

김치찌개 끓이는 법 알려줘

LLM 에 닿지도 않고 1초 만에 끝난다 (실측)

- 찾지 못했습니다
- (최고 유사도 0.216 < 기준 0.4)
- 7-5 에서 지어내던 그 질문

5단계

근거 개수를 1 과 10 으로 바꿔 보세요

1. **k 가 1 이면 근거가 한 조각**
   답이 짧고 빠지는 것이 생긴다

2. **k 가 10 이면 관련 없는 조각까지**
   답이 흐려지고 읽을 글이 늘어 느려진다 — 아래쪽은 0.2 대

3. **7-2 조각 크기의 맞바꿈이 다시**
   많다고 좋은 것이 아니다

4. **기준값은 1등 점수만 본다**
   개수를 바꿔도 막히는 질문은 같다

기본값

3

6단계 — 일부러 실패시키기

모델 서버를 멈추고 질문 — 역추적 대신 한 줄

새 터미널: docker stop ollama

앱은 켜 둔 채로 아무 질문이나 보낸다

- 빨간 상자: 답변을 만들지 못했습니다:
- ConnectionError (실측)
- Ollama 나 Qdrant 가 떠 있는지 확인 안내

VS

docker start ollama

다음 질문부터 정상 — 첫 답은 다시 느리다

- except Exception as e: st.error(...)
- 사용자에게 traceback 을 보이지 않는다
- OpenAI 경로: 키 끝 한 글자 → AuthenticationError

확인 포인트

이 1시간이 끝날 때 확인할 것

1. lecture_kb count 가 11 이다
2. search_test.py 1등이 0.536 · airflow_ops.txt 다
3. threshold.py 로 내 경로의 기준값을 정했다
4. 안 질문은 근거와 답 · 김치찌개는 0.216 < 0.4 로 막힌다
5. ollama 를 멈추면 ConnectionError 한 줄이 보인다

8-4 · 실습 1H 마무리

다음은 정리·회고 (0.5H)

오늘 만든 챗봇의 구조를 한 표로 정리하고, 자주 겪는 오류와 8-5 최종일을 예고합니다

- ✓ 하려는 일 ↔ 코드 요약표
- ✓ 오늘의 체크리스트
- ✓ 자주 겪는 오류 네 가지
- ✓ 8-5 최종 RAG 챗봇 예고

가져갈 것

돌아가는 app.py · 지우지 말 것